

ASTA - 自动化序列分类学智能体

ASTA (Automated Sequence Taxonomy Agent, 自动化序列分类学智能体)

基于智能体驱动序列比对与物种鉴定自动化流程

1 概述

ASTA 是一款全面的自动化序列分类学分析工具，通过智能体实现从原始序列数据到最终分析报告的全流程自动化。流程整合了序列采样、BLAST 比对、分类学注释、统计分析及报告生成等关键步骤，适用于微生物组学、环境样本、临床样本等领域中的物种鉴定与分类学分析。

核心功能：

- 自动化流程执行**：智能体自动驱动所有流程步骤，无需人工干预
- 序列采样与预处理**：支持 FASTQ/FASTA 格式，提供随机采样与格式转换功能
- 高效 BLAST 比对**：多线程并行计算，支持自定义数据库与参数配置
- 分类学注释**：自动获取完整分类层级信息（从界到种）
- 可视化分析**：为各分类层级生成统计图表（风玫瑰图/饼图）
- 自动化报告生成**：以 HTML 和 PDF 格式输出专业分析报告

2 流程架构

本流程包含 5 个顺序执行的步骤：

步骤	脚本	功能
1	01_seqs_sample.sh	序列采样与格式转换
2	02_blastn.sh	BLAST 序列比对
3	03_taxonmy.sh	分类学注释
4	04_statistic.py	统计分析与可视化
5	05_md_converter.py	报告生成 (HTML/PDF)

3 环境要求

3.1 必需的软件工具

- SeqKit** (v2.9.0+) — 序列处理工具
- BLAST+** (v2.17.0+) — 序列比对工具
- TaxonKit** (v0.20.0+) — 分类学信息查询工具
- Python** (v3.12+) — 数据分析与可视化

3.2 必需的 Python 包

```
pip install pandas matplotlib markdown weasyprint
```

3.3 必需的数据库

- **BLAST 数据库**: NCBI 核苷酸数据库, 如 `core_nt`、`nt` 等
- **TaxonKit 数据库**: taxdump 文件 (自动下载至 `~/.taxonkit/` 目录)

4 安装

4.1 方式一：使用 Conda (推荐)

```
# 创建环境并安装依赖
conda create -n asta_pipeline python=3.12
conda activate asta_pipeline
conda install -c bioconda seqkit blast taxonkit
pip install pandas matplotlib markdown weasyprint
```

4.2 方式二：手动安装

各软件请参阅官方文档进行安装:

- SeqKit: <https://github.com/shenwei356/seqkit>
- BLAST+: <https://ftp.ncbi.nlm.nih.gov/blast/executables/blast+/LATEST/>
- TaxonKit: <https://github.com/shenwei356/taxonkit>

5 使用方法

ASTA 支持两种运行模式: **智能体驱动执行 (推荐)** 和 **手动分步执行**。

5.1 模式一：智能体驱动执行 (推荐)

通过智能体 (如 Trae IDE) 运行流程是推荐的方式, 具有以下优势:

- **高度自动化**: 智能体自动驱动所有流程步骤, 无需人工干预
- **智能参数配置**: 智能体协助收集与验证分析参数
- **自动错误处理**: 智能体可诊断并处理常见运行时错误
- **智能报告生成**: 智能体按照模板格式自动生成专业报告

执行步骤:

1. 在智能体环境中打开流程目录
2. 向智能体发出运行命令:

```
用户指令: 运行当前流程
```

3. 智能体将自动执行以下操作:
 - 选择并验证运行时环境
 - 收集并确认分析参数

- 依次执行各步骤
- 生成最终分析报告

5.2 模式二：手动分步执行

如需手动执行流程，请按以下步骤操作：

5.2.1 参数说明

运行流程时需要指定以下参数：

参数	说明	默认值
输入文件	FASTQ/FASTA 序列文件	必填
输出目录	结果输出目录	result/
采样数量	随机采样的序列数量	1000
BLAST 数据库	数据库名称或路径	core_nt
BLAST 线程数	并行计算的线程数	8
最大目标序列数	每个序列保留的最大匹配数	10
Top N	可视化展示的顶级分类单元数量	5

5.2.2 手动执行命令

如需手动执行每个步骤，请使用以下命令：

```
# 1. 序列采样
bash 01_seqs_sample.sh -i input.fq -o sample.fa -n 1000

# 2. BLAST 比对
bash 02_blastn.sh -Q sample.fa -D core_nt -J 48 -M 10 -O blastn_result.tsv

# 3. 分类学注释
bash 03_taxonmy.sh -i blastn_result.tsv -o taxon_info.tsv

# 4. 统计分析（各分类层级）
python3 04_statistic.py -i taxon_info.tsv -r Kingdom -n 5 -o result/
python3 04_statistic.py -i taxon_info.tsv -r Phylum -n 5 -o result/
# ... 其他分类层级

# 5. 报告生成
# Markdown 报告须由智能体根据 template.md 模板和执行结果生成
# 然后转换为 HTML 和 PDF 格式
python3 05_md_converter.py result/seqs_taxonomy_report.md -o result/report
```

注意：第 5 步所需的 Markdown 报告（seqs_taxonomy_report.md）须由智能体根据流程执行结果和 template.md 模板生成。智能体提取软件版本信息，整合分类学统计数据，按照模板格式生成完整报告。

6 输出文件

流程执行完成后，将生成以下文件：

文件	说明
sample<N>.fa	采样后的 FASTA 序列文件
blastn_result.tsv	BLAST 比对结果
taxon_info.tsv	分类学注释信息
taxon_info_<rank>_top<N>_summary.tsv	各分类层级的统计表
taxon_info_<rank>_top<N>_pie.png/pdf	各分类层级的饼图
seqs_taxonomy_report.html	HTML 格式分析报告
seqs_taxonomy_report.pdf	PDF 格式分析报告
run.log	流程执行日志

7 分析报告

生成的报告包含三个主要部分：

- 1. **方法**：流程描述、软件版本、主要参数
- 2. **结果**：各分类层级（从界到种）的统计表与可视化图表
- 3. **结论**：基于分析结果的主要发现与总结

报告格式遵循 `template.md` 中定义的标准结构，确保分析结果的一致性与规范性。

8 示例

8.1 输入文件示例

```
输入文件: /path/to/sample.pure_unmapped_reads.fq
输出目录: result_example
采样数量: 1000
BLAST 线程数: 48
数据库: core_nt
```

8.2 执行结果示例

```
比对成功率: 40.0% (400/1000)
主要类群: 灵长目 (70.5%)、偶蹄目 (23.5%)
主要物种: 人类 (21.5%)、野猪 (20.5%)、恒河猴 (17.0%)
```

8.3 示例图示

